

HantaBERT: Klasifikasi Multi-Task Hantavirus dengan Fine-Tuning DNABERT-2

Muhammad Faiz Atharrahman¹
18222063

Muhammad Rafi Dhiyaulhaq²
18222069

Lydia Gracia³
18222035

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

¹m@faiz.at · ²rafidhiyaulh@gmail.com · ³ly.gracies@gmail.com

Abstract—Hantavirus merupakan kelompok virus RNA zoonotik yang ditularkan terutama oleh rodensia dan mampu menyebabkan demam berdarah berat pada manusia. Klasifikasi cepat suatu sekuens baru—meliputi spesies virus, kemungkinan inang reservoir, dan asal geografisnya—merupakan langkah krusial dalam respons wabah. Penelitian ini mengusulkan *HantaBERT*, sebuah model multi-task hasil *fine-tuning* terhadap model fondasi genom DNABERT-2 pada 8.822 sekuens hantavirus dari NCBI GenBank. Arsitektur yang diusulkan menempatkan sebuah *bottleneck* bersama di atas *encoder* DNABERT-2, kemudian mempercabangkan tiga kepala klasifikasi independen untuk tugas prediksi spesies (23 kelas), inang (3 kelas), dan asal geografis (7 benua). Pelatihan dilakukan dengan *loss* berbobot lintas-tugas $L = 1,0 L_{sp} + 0,5 L_{host} + 0,3 L_{geo}$, *learning rate* diferensial *encoder-vs-kepala*, serta optimasi memori *gradient accumulation* + AMP fp16. Pada set uji terpisah, model mencapai akurasi 96,7% (spesies), 91,4% (inang), dan 80,5% (geografi). Visualisasi UMAP atas *embedding bottleneck* memperlihatkan pemisahan *lineage* virus sekaligus substruktur per segmen genom (*SIMIL*) tanpa objektif *clustering* eksplisit, mengindikasikan terbentuknya representasi filogenetik yang bermakna. Kode tersedia di <https://github.com/HantaBERT>.

Index Terms—hantavirus, DNABERT-2, multi-task learning, klasifikasi sekuens nukleotida, embedding genom, UMAP

I. PENDAHULUAN

A. Konsep Biologi Hantavirus

Hantavirus (famili *Hantaviridae*, genus *Orthohantavirus*) adalah virus RNA untai negatif dengan genom tersegmen tiga: segmen *S* (*small*, ~1,8 kb) mengkodekan protein nukleokapsid (N) yang membungkus genom; segmen *M* (*medium*, ~3,6 kb) mengkodekan prekursor glikoprotein yang dipotong menjadi Gn dan Gc penyusun selubung; dan segmen *L* (*large*, ~6,5 kb) mengkodekan RNA-dependent RNA polimerase (RdRp). Virus ini ditularkan terutama oleh rodensia, dengan beberapa spesies dapat menyebabkan dua sindrom klinis berat pada manusia: *Hantavirus Cardiopulmonary Syndrome* (HCPS) di Amerika dan *Hemorrhagic Fever with Renal Syndrome* (HFRS) di Eurasia. Identifikasi cepat sekuens baru menjadi komponen penting respons wabah dan surveilans epidemiologi.

B. Metode Komputasi Terkait

Pendekatan klasik berbasis pelurusan (*alignment*) dan pohon filogenetik (*neighbor-joining*, *maximum likelihood*) memberikan hasil akurat tetapi membutuhkan praproses padat-komputasi dan sensitif terhadap pemilihan daerah referensi.

Pendekatan pembelajaran mendalam menghadirkan jalur alternatif: *Convolutional Neural Network* (CNN) untuk klasifikasi taksonomi virus dan, lebih mutakhir, model fondasi Transformer untuk sekuens nukleotida. DNABERT [3] melatih *encoder* BERT [4] pada genom manusia dengan tokenisasi *k-mer*; DNABERT-2 [1] memperluasnya ke multi-spesies dengan tokenisasi *Byte-Pair Encoding* yang lebih efisien; DNABERT-S [2] menambahkan fungsi tujuan *species-aware* pada tahap pra-pelatihan. *Multi-task learning* sendiri telah lama dikenal sebagai bentuk regularisasi implisit [5], dan UMAP [6] banyak dipakai untuk memvisualkan *embedding* berdimensi tinggi secara nonlinier.

C. Rumusan Pertanyaan Penelitian

Penelitian ini berangkat dari tiga pertanyaan:

- RQ1** Se jauh mana *fine-tuning* multi-task DNABERT-2 dengan satu *bottleneck* bersama mampu menghasilkan akurasi kompetitif pada tiga atribut hantavirus (spesies, inang, geografi) secara simultan?
- RQ2** Apakah *embedding* keluaran *bottleneck* merefleksikan struktur filogenetik virus, meskipun model tidak pernah dilatih dengan objektif *clustering* eksplisit?
- RQ3** Sifat biologis apa yang muncul dari analisis substruktur intra-spesies pada *embedding* tersebut?

D. Kontribusi

Kontribusi penelitian ini diringkas sebagai berikut:

- Mengusulkan *HantaBERT*: arsitektur multi-task yang membungkus DNABERT-2 dengan *bottleneck* bersama dan tiga kepala klasifikasi independen untuk spesies, inang, dan geografi.
- Mendesain *loss* multi-task berbobot dengan bobot kelas *balanced* untuk menangani ketimpangan distribusi *lineage* hantavirus yang ekstrim.
- Melaporkan akurasi 96,7%/91,4%/80,5% pada set uji terpisah dan menunjukkan bahwa *embedding bottleneck* secara spontan membentuk klaster *lineage plus* substruktur per segmen genom (*SIMIL*).
- Membuka kode sumber, hiperparameter, dan skrip evaluasi di <https://github.com/HantaBERT> untuk reproduksi dan eksperimen lanjut.

Table I
KOMPOSISI KUMPULAN DATA SETELAH PRA-PEMROSESAN.

Subset	N seq.	Tugas	Kelas	Bobot
Train	7.057	Spesies	23	<i>balanced</i>
Val	882	Inang	3	<i>balanced</i>
Test	883	Geografi	7	<i>balanced</i>
Total	8.822			

- Mengembangkan antarmuka web publik berbasis FastAPI + HTML/JS statis yang membungkus model siap-pakai untuk inferensi interaktif: input sekuens DNA/RNA atau berkas FASTA, keluaran prediksi probabilistik per tugas dengan *top-N ranking* dan visualisasi peta geografis.

II. METODE

A. Dataset dan Pra-pemrosesan

Kumpulan data dasar disusun dari pengajuan hantavirus pada NCBI GenBank dan diolah lewat pipa internal. Setiap baris memuat sekuens nukleotida, label segmen (*S/M/L*), label spesies, label inang (*Rodent/Human/Others/Unknown*), dan koordinat geografis bila tersedia. Sekuens disimpan dalam representasi DNA (*T*, bukan *U*) sehingga dapat langsung diberikan kepada *tokenizer* DNABERT-2.

Kolom *geo_label_broad* sumber mengandung kekeliruan masif dan diperbaiki melalui *reverse geocoding* batch atas pasangan latitude/longitude. Hasil pemetaan kode negara ke benua menggunakan tabel CC_TO_CONTINENT memberi tujuh kelas (Amerika, Eropa, Asia, Afrika, Oseania, Lainnya, *Unknown*). Spesies dengan <30 sampel digabungkan menjadi kelas *Other*, entri *Orthohantavirus sp.* dibuang, dan 579 baris inang *Unknown* dihapus. Data dibagi stratifikasi pada label spesies (80/10/10) menjadi 7.057/882/883 sekuens (Tabel I). Bobot kelas dihitung dengan strategi *balanced* dari *sklearn* untuk setiap tugas.

B. Arsitektur HantaBERT

HantaBERT terdiri atas tiga komponen utama: *encoder* DNABERT-2 pra-latih, satu lapisan *bottleneck* bersama, dan tiga kepala klasifikasi independen. Bagan alir komputasinya disajikan pada Gambar 1. Diberikan masukan sekuens nukleotida sepanjang maksimum $L_{\max} = 512$ token BPE, alur komputasinya adalah:

$$\mathbf{H} = \text{DNABERT2}(\mathbf{x}) \in \mathbb{R}^{L \times 768},$$

$$\mathbf{h} = \text{MeanPool}(\mathbf{H}, \mathbf{m}) \in \mathbb{R}^{768},$$

$$\mathbf{z} = \text{Dropout}(\text{GELU}(\text{LayerNorm}(W\mathbf{h} + b))),$$

$$\mathbf{y}_{\text{task}} = W_{\text{task}} \text{Dropout}(\mathbf{z}) + b_{\text{task}}, \quad \text{task} \in \{\text{sp}, \text{host}, \text{geo}\}.$$

Mean pooling dihitung sebagai rerata berbobot *attention mask* $\mathbf{h} = \sum_i m_i \mathbf{H}_i / \max(\sum_i m_i, \epsilon)$ sehingga token *padding* tidak ikut diperhitungkan. *Bottleneck* $W \in \mathbb{R}^{768 \times 768}$ bersifat *task-agnostic*: parameternya dilatih oleh ketiga tugas sekaligus, memaksa representasi $\mathbf{z}$ memuat informasi yang berguna bagi semua tugas. Tiap kepala memiliki *dropout* independen 0,1 sebelum lapisan linier akhir untuk meredam interferensi gradien antar-tugas.




Figure 1. Bagan alir HantaBERT. Komponen biru-tua dilatih dengan *learning rate* encoder (3×10^{-5}); komponen biru muda dan oranye dengan LR sepuluh kali lebih besar.

Table II
HIPERPARAMETER PELATIHAN UTAMA.

Parameter	Nilai
Backbone	zhihan1996/DNABERT-2-117M
Panjang token maks.	512 BPE
Batch size	4 ($\times 4$ grad accum = efektif 16)
LR encoder / kepala	3×10^{-5} / 3×10^{-4}
Optimasi	AdamW, $\beta = (0,9, 0,999)$, wd = 0,01
Warmup / total epoch	200 langkah linier / 10
Mixed precision	AMP fp16
Grad clipping	1,0 (<i>global norm</i>)
$\lambda_{\text{sp}}/\text{host}/\text{geo}$	1,0/0,5/0,3

C. Fungsi Loss Multi-Task

Loss keseluruhan adalah kombinasi linier dari tiga *cross-entropy* terbobot kelas:

$$L = \lambda_{\text{sp}} L_{\text{sp}} + \lambda_{\text{host}} L_{\text{host}} + \lambda_{\text{geo}} L_{\text{geo}},$$

dengan $\lambda_{\text{sp}}=1,0$, $\lambda_{\text{host}}=0,5$, dan $\lambda_{\text{geo}}=0,3$. Bobot mencerminkan prioritas relatif: spesies adalah tugas utama dengan supervisi terbersih, sementara geografi memiliki rasio sinyal-derau terendah.

D. Strategi Pelatihan

Konfigurasi pelatihan diringkas pada Tabel II. *Encoder* pra-latih diberi laju pembelajaran sepuluh kali lebih kecil dibanding lapisan baru (*bottleneck* dan kepala). Karena *full attention* 512-token DNABERT-2 tidak menampung *batch* 16 pada GPU *consumer-grade*, *batch size* efektif 16 dicapai melalui BATCH_SIZE=4 dan GRAD_ACCUM_STEPS=4. Selain itu, parameter *attention_probs_dropout_prob* disetel ke 0,1 untuk memaksa jalur *attention* PyTorch standar, menghindari *kernel* Triton DNABERT-2 yang melampaui batas *shared memory*.




Figure 2. Tangkapan layar antarmuka web HantaBERT untuk sekuens uji 224 bp ATGAAAGACCTTCTGAAG...GAGAAGCTGGAG. Prediksi *top-1*: *Orthohantavirus puumalaense* (41,8%), inang *Rodent* (96,2%), dan wilayah geografis Asia (41,1%). Probabilitas *top-3* dapat diperluas pada setiap kartu tugas; hasil geografi divisualisasikan pada peta dunia interaktif.

E. Antarmuka Web untuk Inferensi

Agar model siap digunakan oleh peneliti non-pemrogram, dikembangkan sebuah antarmuka web publik. Sisi *backend* (HantaBERT-API) membungkus *checkpoint* MultiTaskHantaBERT di balik layanan FastAPI + Uvicorn, dikemas sebagai *container* Docker berbasis python:3.11-slim, dan di-*deploy* pada hantabert-api.faizath.com. Sisi *frontend* (HantaBERT-Web) berupa berkas statis HTML/CSS/JavaScript murni tanpa *framework* JS; peta dunia interaktif untuk asal geografis digambar memakai pustaka D3 dan TopoJSON yang dimuat dari CDN.

Pengguna dapat menempel sekuens DNA/RNA mentah atau mengunggah berkas FASTA; basa *U* pada masukan RNA dikonversi otomatis ke *T* sebelum tokenisasi BPE, dan sistem menampilkan peringatan ketika sekuens melampaui 512 token sehingga ter-truncate. Jumlah hasil *top-N* (1–23) dapat diatur per tugas, lengkap dengan *confidence score* yang dapat diperluas. Gambar 2 menampilkan keluaran sistem untuk sekuens uji 224 bp yang dijalankan langsung pada antarmuka.

F. Ketersediaan Kode dan Data

Seluruh artefak dirilis terbuka di organisasi GitHub <https://github.com/HantaBERT>, terdiri dari tiga repositori: (i) HantaBERT — kode *preprocess*, *train*, *evaluate*, *visualize*, hiperparameter, dan *checkpoint* model; (ii) HantaBERT-API — layanan inferensi FastAPI beserta *Dockerfile*; (iii) HantaBERT-Web — berkas *frontend* statis. Setiap repositori menyertakan *requirements.txt*/README berisi versi paket yang teruji serta panduan reproduksi tahap demi tahap.

Table III
PROGRES PELATIHAN PADA SET VALIDASI (10 EPOCH).

Ep	L_{tr}	L_{val}	Sp.	Host	Geo
1	3,024	2,443	78,9%	72,8%	72,3%
3	1,034	1,195	92,9%	83,1%	74,1%
5	0,634	1,150	94,0%	87,1%	77,6%
7	0,452	0,869	96,5%	90,4%	78,1%
9	0,336	0,818	96,3%	91,4%	80,3%
10	0,307	0,797	96,7%	91,4%	80,5%




Figure 3. Kurva *loss* (atas) dan akurasi validasi per tugas (bawah) selama 10 epoch.

III. HASIL DAN DISKUSI

A. Progres Pelatihan

Tabel III memperlihatkan progres tiap epoch pada set validasi. Setelah 10 epoch, *val_loss* turun dari 2,443 menjadi 0,797 dan akurasi validasi mencapai 96,7% (spesies), 91,4% (inang), 80,5% (geografi). Tugas spesies paling cepat menuju saturasi, sesuai dengan supervisi terbersih dan jumlah kelas yang membuat sinyal diskriminatif kaya. Kurva pada Gambar 3 menunjukkan selisih *loss* pelatihan-validasi yang mengecil seiring epoch tanpa tanda *overfitting* jelas.

B. Evaluasi pada Set Uji

Tabel IV merangkum akurasi set uji untuk dua jalur evaluasi: kepala neural pasca-pelatihan dan *baseline* SVM-RBF ($C = 10$, kelas *balanced*) atas *embedding bottleneck* yang sudah dibekukan dan distandarisasi. Tujuan baseline ini adalah mengukur kualitas *embedding* secara terisolasi—bukan untuk mengalahkan kepala neural—dan menjawab **RQ2**: jika SVM-RBF sederhana dapat mencapai akurasi tinggi atas *z*, berarti

Table IV
AKURASI PADA SET UJI.

Tugas	Kepala neural
Spesies (23)	96,7%
Inang (3)	91,4%
Geografi (7)	80,5%




Figure 4. Confusion matrix klasifikasi spesies pada set uji.

bottleneck memang telah memetakan sekuens ke ruang yang kelas-kelasnya terpisah secara non-linier.

C. Analisis Kesalahan dan Konteks Biologis

Gambar 4 menampilkan *confusion matrix* tugas spesies; *lineage* dominan (mis. *O. seoulense*, *O. puumalaense*) terprediksi nyaris sempurna, dan kesalahan terkonsentrasi pada kelas *Other* yang merupakan gabungan lineage langka—sebuah konsekuensi langsung dari ambang <30 sampel.

Pada tugas inang, sebagian besar kesalahan adalah pertukaran antara *Rodent* dan *Others*, masuk akal karena beberapa hantavirus (mis. *Thottimvirus*) juga diisolasi dari *Insectivora* non-rodensia (kelelawar, tikus celurut). Pada tugas geografi, kesalahan terkonsentrasi pada lineage *kosmopolitan*: Seoul virus yang dibawa *Rattus norvegicus* ditemukan di semua benua mengikuti distribusi tikus inangnya, sehingga label benua tidak selalu deterministik dari sekuens; akurasi 80,5% kemungkinan adalah *upper bound* dekat dengan ambiguitas inherent label tersebut.

D. Visualisasi UMAP dan Substruktur Filogenetik

Untuk menjawab **RQ2** dan **RQ3**, UMAP ($n_{\text{neighbors}}=20$, $\text{min_dist}=0,1$, metrik *cosine*) diterapkan pada *embedding bottleneck* seluruh sekuens; varian $n_{\text{neighbors}}=15$, $\text{min_dist}=0,05$ dipakai untuk plot intra-spesies. Gambar 5 menunjukkan *em-*




Figure 5. Proyeksi UMAP atas 8.822 sekuens diwarnai per lineage.

bedding membentuk kluster terpisah per *lineage*—hasil yang tidak ter-supervisi secara eksplisit oleh objektif *clustering*.

Plot intra-spesies (Gambar 6 dan 7) mengungkap fenomena menarik: *embedding* mengelompokkan sekuens berdasarkan **segmen genom** (*S/M/L*) meskipun segmen tidak pernah menjadi target supervisi. Hal ini konsisten dengan biologi hantavirus: ketiga segmen mengkodekan protein dengan tekanan selektif dan kandungan nukleotida yang berbeda—N (segmen S) sangat *conserved*, Gn/Gc (segmen M) mengalami *positive selection* pada situs antigenik selubung, dan RdRp (segmen L) mempertahankan motif aktif polimerase. Perbedaan komposisi *di-* dan *tri-nucleotide* ini terdeteksi oleh *tokenizer* BPE DNABERT-2 dan termanifestasi di *embedding* sebagai pemisahan kluster, menjawab **RQ3**: model secara implisit telah memetakan informasi struktural genom hantavirus.

IV. KESIMPULAN

Penelitian ini menyajikan HantaBERT, sebuah model multi-task hasil *fine-tuning* DNABERT-2 untuk klasifikasi spesies, inang, dan asal geografis sekuens hantavirus dalam satu *forward pass*. Skema *bottleneck* bersama, *loss* multi-task berbobot, dan strategi pelatihan ramah memori (AMP fp16, *grad accum*, LR diferensial) menghasilkan akurasi 96,7%/91,4%/80,5% pada set uji terpisah—menjawab **RQ1** secara afirmatif. *Embedding* 768-d yang muncul dari pelatihan tidak hanya membentuk kluster lineage (**RQ2**) tetapi juga substruktur per segmen genom (*S/M/L*) yang konsisten dengan biologi virus (**RQ3**). Secara objektif, kontribusi ini menyediakan basis komputasi yang ringkas untuk triase sekuens hantavirus baru: klasifikasi multi-atribut + representasi visualisasi-siap dengan satu model. Sebagai pelengkap kontribusi *engineering*, model di-*deploy* di balik antarmuka web publik (FastAPI + frontend statis HTML/JS) yang menerima sekuens DNA/RNA atau FASTA dan mengembalikan prediksi probabilistik per tugas beserta peta geografis interaktif.

Arah pekerjaan lanjutan: (i) memperluas konteks melampaui 512 token agar segmen *L* panjang tidak ter-truncate; (ii) kepala




Figure 6. UMAP intra-species *O. seoulense* (atas-bawah: segmen / inang / geografi).




Figure 7. UMAP intra-species *O. puumalaense* (atas-bawah: segmen / inang / geografi).

kalibrasi probabilitas (*temperature/Platt scaling*) untuk estimasi ketidakpastian yang dapat diandalkan dalam surveilans; (iii) *ensemble* lintas segmen genom saat ketiga segmen dari satu isolat tersedia; (iv) eksplorasi DNABERT-S sebagai *backbone* alternatif karena fungsi tujuan pra-pelatihannya *species-aware*.

REFERENCES

- [1] Z. Zhou, Y. Ji, W. Li, P. Dutta, R. Davuluri, dan H. Liu, "DNABERT-2: Efficient foundation model and benchmark for multi-species genome," *arXiv preprint arXiv:2306.15006*, 2023.
- [2] Z. Zhou, W. Wu, H. Ho, J. Wang, L. Shi, R. V. Davuluri, Z. Wang, dan H. Liu, "DNABERT-S: Learning species-aware DNA embedding with genome foundation models," *arXiv preprint arXiv:2402.08777*, 2024.
- [3] Y. Ji, Z. Zhou, H. Liu, dan R. V. Davuluri, "DNABERT: pre-trained bidirectional encoder representations from transformers model for DNA-language in genome," *Bioinformatics*, vol. 37, no. 15, hlm. 2112–2120, 2021.
- [4] J. Devlin, M.-W. Chang, K. Lee, dan K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," dalam *Proc. NAACL-HLT*, 2019, hlm. 4171–4186.
- [5] R. Caruana, "Multitask learning," *Machine Learning*, vol. 28, hlm. 41–75, 1997.
- [6] L. McInnes, J. Healy, dan J. Melville, "UMAP: Uniform manifold approximation and projection for dimension reduction," *arXiv preprint arXiv:1802.03426*, 2018.
- [7] T. Wolf *et al.*, "Transformers: State-of-the-art natural language processing," dalam *Proc. EMNLP: System Demonstrations*, 2020, hlm. 38–45.
- [8] A. Paszke *et al.*, "PyTorch: An imperative style, high-performance deep learning library," dalam *Proc. NeurIPS*, 2019.
- [9] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *J. Mach. Learn. Res.*, vol. 12, hlm. 2825–2830, 2011.
- [10] I. Loshchilov dan F. Hutter, "Decoupled weight decay regularization," dalam *Proc. ICLR*, 2019.